

Odporność sieci lotniczej i bezpieczeństwo operacyjne

Hurtownia danych DWH Aviation — dokumentacja finalna

Maciej Winkler, Kamila Więckowska, Nazarii Bihniak

Czerwiec 2026

Spis treści

1	Cel projektu i planowane korzyści	2
2	Architektura rozwiązania	2
3	Opis wykorzystywanych zbiorów danych	4
4	Opis procesu ETL	4
4.1	Bronze → Silver — oczyszczanie i standaryzacja	5
4.2	Silver → Gold — integracja i ładowanie modelu (ELT)	5
5	Model fizyczny hurtowni danych	6
6	Implementacja warstwy BI i raportów (Power BI)	7
6.1	Dostęp do danych i konfiguracja modelu	7
6.2	Kluczowe miary i atrybuty	8
6.2.1	Kolumny obliczeniowe dodane w warstwie raportowej	10
6.3	Hierarchie analityczne	10
6.4	Obserwacje dotyczące jakości danych istotne dla raportów	11
6.5	Realizacja raportów	12
6.5.1	Raport 1: Propagacja opóźnień	12
6.5.2	Raport 2: Incydenty FAA	13
6.5.3	Raport 3: Wzorce opóźnień	14
6.5.4	Filtry raportu	14
7	Podsumowanie rezultatów	15
8	Podział pracy w zespole	15
9	Testy funkcjonalne	16

1 Cel projektu i planowane korzyści

Celem projektu jest zbudowanie hurtowni danych (Data Warehouse) w architekturze medalionowej na platformie Microsoft Azure, integrującej trzy niezależne źródła danych lotniczych w jeden spójny model analityczny służący do oceny **odporności sieci lotniczej** oraz **bezpieczeństwa operacyjnego**.

Rozwiązanie integruje:

- **BTS On-Time Performance** (Bureau of Transportation Statistics) — dane o punktualności lotów krajowych w USA (odloty, przyloty, opóźnienia z podziałem na przyczyny, odwołania);
- **FAA Wildlife Strike Database** — zgłoszenia zderzeń statków powietrznych ze zwierzętami (faza lotu, poziom uszkodzeń, czas wyłączenia z eksploatacji, koszty);
- **OpenFlights** — słownik lotnisk (kody IATA/ICAO, lokalizacja geograficzna, strefa czasowa).

Odbiorca rozwiązania. Głównymi odbiorcami są analitycy operacyjni portów lotniczych, menedżerowie operacji linii lotniczych oraz zespoły ds. bezpieczeństwa i ryzyka. Hurtownia odpowiada na pytania, na które pojedyncze źródło nie jest w stanie odpowiedzieć samodzielnie — łączy punktualność, ruch lotniczy i incydenty środowiskowe w jednym modelu.

Planowane korzyści.

- *Identyfikacja węzłów propagacji opóźnień* — wskaźnik DPI (Delay Propagation Index) pozwala wskazać lotniska, które generują efekt kaskadowy opóźnień w całej sieci, co umożliwia ukierunkowanie działań naprawczych tam, gdzie dają największy efekt.
- *Kwantyfikacja ryzyka środowiskowego* — wskaźnik WIR (Wildlife Impact Ratio) przelicza liczbę incydentów ze zwierzętami na liczbę operacji, umożliwiając porównanie lotnisk niezależnie od ich wielkości i priorytetyzację inwestycji w prewencję.
- *Benchmarking punktualności* — wskaźnik OTP (On-Time Performance) umożliwia porównanie przewoźników i analizę wzorców opóźnień w czasie (godzina, dzień tygodnia).
- *Decyzje oparte na danych* — wsparcie planowania siatki połączeń, alokacji zasobów oraz działań ograniczających ryzyko, dzięki jednolitemu, zintegrowanemu i zweryfikowanemu jakościowo zbiorowi danych.

2 Architektura rozwiązania

Rozwiązanie zbudowano na platformie Microsoft Azure w **architekturze medalionowej** (Bronze → Silver → Gold), która porządkuje dane według stopnia ich przetworzenia i zapewnia rozdział odpowiedzialności między kolejnymi warstwami.

DWH Aviation — Architektura end-to-end

Architektura medalionowa · Bronze → Silver → Gold · Microsoft Azure · schemat gold



Rysunek 1: Architektura end-to-end hurtowni DWH Aviation (warstwy Bronze/Silver/Gold, orkiestracja Azure Data Factory).

Komponenty Azure.

- **Azure Data Lake Storage Gen2** (stdwhaviationdev) — magazyn warstw Bronze i Silver, podzielony na kontenery **bronze**, **silver**, **quarantine** (wiersze odrzucone) oraz **gold**.
- **Azure Data Factory** (df-dwh-aviation-dev) — orkiestracja całego przepływu: potoki (pipelines), przepływy mapujące (Mapping Data Flows) oraz wyzwalacze zdarzeń magazynu (Storage Event Triggers).
- **Azure SQL Database** — **warstwa Serverless** (db-aviation-gold) — hurtownia docelowa (schemat gold) w modelu gwiazdy; tryb bezserwerowy z automatycznym wstrzymaniem (auto-pause) optymalizuje koszty w środowisku akademickim.
- **Power BI** — warstwa raportowa łącząca się z bazą db-aviation-gold.

Przepływ danych.

1. **Bronze (surowe)**. Pliki źródłowe (CSV/ZIP z BTS, FAA, OpenFlights) ładują w kontenerze **bronze** bez modyfikacji — pełna kopia źródła.
2. **Bronze → Silver (oczyszczanie)**. Trzy przepływy mapujące (DF_Bronze_to_Silver_BTS/FAA/OF) standaryzują dane: przycięcie i ujednolicenie wielkości liter, parsowanie dat, zamiana pustych ciągów na NULL, zamiana NULL→0 dla miar opóźnień oraz dodanie kolumn audytowych (Load_Date, ETL_Batch_ID, Record_Source). Wynik zapisywany jest jako Parquet (kompresja snappy).
3. **Silver → Gold (integracja, ELT)**. Potok **Silver_to_Gold** kopiuje dane Silver do tabel pomocniczych (stg.*), po czym procedura składowana **sp_Silver_to_Gold_Master** ładuje wymiary i fakty:

wymiary SCD Type 2 (Dim_Airport, Dim_Carrier) z użyciem skrótu Hash_Diff (SHA-256), wymiar SCD Type 1 / MERGE (Dim_Aircraft), a następnie fakty (Fact_Flights, Fact_Strikes) z polityką klucza zastępczego SK = -1 dla braków dopasowania. Ładowanie faktów jest *idempotentne* względem ETL_Batch_ID (DELETE batcha + INSERT).

4. **Gold → Power BI (raporty).** Power BI importuje 9 tabel schematu gold i udostępnia trzy raporty biznesowe.

3 Opis wykorzystywanych zbiorów danych

Hurtownia integruje trzy niezależne, publicznie dostępne źródła danych lotniczych. Każde z nich trafia do warstwy **bronze** jako surowy plik, skąd jest automatycznie pobierane przez wyzwalacz zdarzeń magazynu (Storage Event Trigger) uruchamiający przetwarzanie.

Tabela 1: Charakterystyka wykorzystywanych zbiorów danych

Źródło	Dostęp	Format	Odświeżanie	Zakres / wolumen
BTS On-Time Performance (Bureau of Transportation Statistics, US DOT)	Publiczny portal TranStats (pobranie ręczne / wsad miesięczny)	CSV (T_ONTIME_REPORTING)	Miesięczne (nowy plik na miesiąc)	2025, 12 miesięcy, ~200–230 MB/miesiąc, 6 991 619 rekordów lotów
FAA Wildlife Strike Database	Publiczny zrzut bazy FAA	CSV	Kwartalny zrzut całościowy	1990–2026, 342 830 incydentów
OpenFlights	Otwarty zbiór (openflights.org)	CSV (airports.dat)	Statyczny / sporadyczny	~7 700 lotnisk (słownik referencyjny)

Dostęp i bezpieczeństwo. Wszystkie warstwy danych przechowywane są w Azure Data Lake Storage Gen2 (**stdwhaviationdev**), a hurtownia docelowa w Azure SQL Database (**db-aviation-gold**). Dostęp do bazy realizowany jest przez uwierzytelnianie SQL oraz Microsoft Entra ID, z listą dozwolonych adresów IP (firewall) na poziomie serwera.

Częstotliwość odświeżania. Model odświeżania jest sterowany zdarzeniami: pojawienie się nowego pliku w kontenerze **bronze** uruchamia odpowiedni wyzwalacz (**Trigger_BTS_Upload**, **Trigger_FAA_Upload**, **Trigger_OF_Upload**), który startuje przetwarzanie Bronze→Silver. Dane BTS dostarczane są w cyklu miesięcznym, dane FAA jako okresowy (kwartalny) zrzut całościowy, a słownik OpenFlights ma charakter statyczny i jest odświeżany sporadycznie.

4 Opis procesu ETL

Proces ETL/ELT zrealizowano w Azure Data Factory (**df-dwh-aviation-dev**) w architekturze medalionowej. Składa się z dwóch zasadniczych etapów: oczyszczania danych (Bronze→Silver, realizowanego jako

Mapping Data Flows) oraz integracji i ładowania modelu gwiazdy (Silver→Gold, realizowanego jako ELT za pomocą procedur składowanych).

4.1 Bronze → Silver — oczyszczanie i standaryzacja

Dla każdego źródła zdefiniowano osobny przepływ mapujący (DF_Bronze_to_Silver_BTS, _FAA, _OF). Wspólny wzorzec transformacji obejmuje:

- **Standaryzację tekstu** — przycięcie spacji (`trim`) i ujednolicenie wielkości liter (`upper`) dla kodów (przewoźnik, lotnisko, rejestracja).
- **Normalizację wartości pustych** — zamianę pustych ciągów na NULL oraz zamianę NULL→0 dla miar opóźnień (Carrier/Weather/NAS/Security/ Late Aircraft Delay), aby umożliwiać agregacje.
- **Parsowanie dat** — konwersję pól tekstowych na typ daty (`toDate/toTimestamp`) z maską zgodną z formatem źródła (BTS: M/d/yyyy h:mm:ss a).
- **Kolumny audytowe** — dodanie `Load_Date`, `ETL_Batch_ID` oraz `Record_Source` do każdego rekordu (transformacja `AddAudit`).
- **Zapis** — do formatu Parquet (kompresja snappy) w warstwie `silver`.

Dla danych BTS przetwarzanie odbywa się w pętli `ForEach` po 12 miesiącach 2025 r., co daje 12 plików Parquet (po jednym na miesiąc).

4.2 Silver → Gold — integracja i ładowanie modelu (ELT)

Potok `Silver_to_Gold` najpierw kopiuje dane z warstwy Silver do tabel pomocniczych (`stg.*`) w bazie SQL (z opcją pomijania wierszy niezgodnych i przekierowaniem ich do kontenera `quarantine`), a następnie wywołuje procedurę nadrzędną `sp_Silver_to_Gold_Master`, która orkiestruje ładowanie wymiarów i faktów w ustalonej kolejności zależności:

- **Dim_Airport, Dim_Carrier** — **SCD Type 2**. Wykrywanie zmian za pomocą skrótu `Hash_Diff` (SHA-256). Przy zmianie atrybutów bieżąca wersja jest zamykana (`Valid_To, Is_Current = 0`), a nowa wstawiana jako aktualna. Walidacja kodów: IATA [A-Z]{3}, ICAO [A-Z]{4}.
- **Dim_Aircraft** — **SCD Type 1 (MERGE)**. Aktualizacja w miejscu po kluczu naturalnym `Tail_Number`; dekodowanie jednoliterowych kodów FAA `AC_CLASS` (np. A→Airplane) i `TYPE_ENG` na pełne nazwy słownikowe.
- **Dim_Date, Dim_Time, Dim_Flight_Phase, Dim_Damage_Level** — **wymiary statyczne** generowane skryptem / zasilane słownikowo.
- **Fact_Flights** — **ładowanie idempotentne**. `DELETE` wierszy danego `ETL_Batch_ID` + `INSERT` ze złączeniami `LEFT JOIN` do wszystkich wymiarów; klucze czasu liczone z formatu HHMM (minuta doby); wartości opóźnień ograniczane do zakresu `[-200, 1500]`.
- **Fact_Strikes** — **pełny reload** z deduplikacją po `INDEX_NR`; klucz batcha wyprowadzany z daty incydentu.

Integralność (sentinel SK = -1). Rekordy faktów bez dopasowania w wymiarze otrzymują klucz zastępczy `SK = -1` (wiersz sentinela istnieje w każdym wymiarze) zamiast wartości NULL. Eliminuje to problem znikania wierszy przy złączeniach w raportach i gwarantuje brak NULL w kluczach obcych.

Tabela	Typ	Klucz główny (typ)	Wiersze	Uwagi
Dim_Date	Wymiar	Date_SK (INT, YYYY-MMDD)	13 514	statyczny, 1990–2026
Dim_Time	Wymiar	Time_SK (SMALLINT)	1 441	statyczny, minuta doby
Dim_Airport	Wymiar	Airport_SK (INT, IDENTITY)	6 071	SCD Type 2
Dim_Carrier	Wymiar	Carrier_SK (INT, IDENTITY)	14	SCD Type 2
Dim_Aircraft	Wymiar	Aircraft_SK (INT, IDENTITY)	46 773	SCD Type 1
Dim_Flight_Phase	Wymiar	Phase_SK (SMALLINT)	11	słownikowy
Dim_Damage_Level	Wymiar	Damage_SK (SMALLINT)	7	słownikowy

Typy danych i wymagalność. Klucze zastępcze (surrogate keys) są typu całkowitego (INT/BIGINT/SMALLINT), przy czym Date_SK ma postać liczby YYYYMMDD. Klucze obce w tabelach faktów są NOT NULL — braki dopasowania reprezentuje wartość -1 (sentinel), nigdy NULL. Miary (opóźnienia, koszty, liczby) są nullable, gdy źródło nie podaje wartości. Kody i atrybuty tekstowe mają ograniczoną długość (np. IATA_Code VARCHAR(3), ICAO_Code VARCHAR(4), Hash_Diff CHAR(64)).

Ograniczenia i relacje. Każda tabela posiada klucz główny (PRIMARY KEY), a wymiary — ograniczenia unikalności (np. UQ_Dim_Date_FullDate) oraz reguły domenowe (CHECK, np. Month BETWEEN 1 AND 12, Day_Of_Week BETWEEN 1 AND 7). Relacje realizują klucze obce z tabel faktów do wymiarów: Fact_Flights odwołuje się do Dim_Date (data lotu i 4 klucze czasu), Dim_Airport (lotnisko źródłowe i docelowe), Dim_Carrier oraz Dim_Aircraft; Fact_Strikes do Dim_Date, Dim_Time, Dim_Airport, Dim_Aircraft, Dim_Carrier, Dim_Flight_Phase oraz Dim_Damage_Level. Wymiary SCD Type 2 (Dim_Airport, Dim_Carrier) zawierają dodatkowo kolumny wersjonowania Valid_From, Valid_To, Is_Current oraz Hash_Diff.

6 Implementacja warstwy BI i raportów (Power BI)

Poniższa sekcja opisuje finalną implementację warstwy analitycznej i raportowej projektu, zrealizowaną w Power BI Desktop na bazie modelu gold z Azure SQL Database (db-aviation-gold). W stosunku do planu z poprzedniego etapu część elementów została zaimplementowana bez zmian, część natomiast uległa modyfikacji w trakcie pracy, głównie ze względu na rzeczywistą strukturę danych w warstwie gold..

6.1 Dostęp do danych i konfiguracja modelu

Połączenie z hurtownią zostało skonfigurowane w Power BI Desktop przy użyciu uwierzytelniania SQL (SQL Authentication) do bazy db-aviation-gold (Azure SQL Database, warstwa Serverless). Dane są importowane (Import mode) z dziewięciu tabel schematu gold:

- Dim_Aircraft, Dim_Airport, Dim_Carrier, Dim_Date, Dim_Time, Dim_Flight_Phase, Dim_Damage_Level
- Fact_Flights, Fact_Strikes

Ponieważ wszystkie tabele po imporcie zostały automatycznie poprzedzone w Power BI prefiksem "gold " (np. 'gold Fact_Flights'), wszystkie miary i kolumny obliczeniowe odwołują się do pól w formie 'gold TabelaNazwa'[Kolumna]. Jest to mała różnica względem nazw z DDL, ale wpływa na zapis każdej formuły DAX w modelu.

Dodatkowo w modelu utworzono pustą tabelę pomocniczą **_Measures** (**_Measures** = {1}), która nie zawiera danych z hurtowni, a służy jako kontener porządkujący wszystkie miary DAX w jednym miejscu.

6.2 Kluczowe miary i atrybuty

Tabela 3 przedstawia finalny zestaw miar wykorzystanych w raportach. W stosunku do planu z KM2 (Tabela 2) zestaw został rozszerzony o dwie miary, które okazały się potrzebne w trakcie budowy raportu 3 oraz strony testowej: **Flight Count** (licznik lotów, wykorzystany m.in. jako wielkość punktów na wykresie rozrzutu w Raporcie 1) oraz **Cancellation Rate by Reason** (wariant Cancellation Rate liczony per przyczyna odwołania).

Tabela 3: Finalny zestaw kluczowych miar i atrybutów wykorzystanych w warstwie BI

Miara / atrybut	Źródło danych	Definicja
Late Aircraft Delay	Fact_Flights (Late_Aircraft_Delay_Min)	Średnia liczba minut opóźnienia wynikająca z opóźnienia poprzedniego rejsu tego samego samolotu. Wykorzystywana w Raporcie 1 jako oś Y wykresu rozrzutu względem DPI.
Delay Propagation Index (DPI)	Fact_Flights (Late_Aircraft_Delay_Min, Dep_Delay_Pos_Min)	Stosunek liczby lotów z opóźnieniem od poprzedniego samolotu do liczby lotów z opóźnionym odlotem, liczony per lotnisko. Wartość > 1 oznacza, że lotnisko generuje więcej opóźnień kaskadowych, niż samo ich "dostaje". Główna miara raportu 1, użyta na mapie, w rankingu TOP 10 oraz na wykresie trendu.
Average Arrival Delay	Fact_Flights (Dep_Delay_Pos_Min / opóźnienie przylotu)	Średnie opóźnienie przylotu, liczone per lotnisko, przewoźnik albo - w Raporcie 3 - per godzina odlotu i dzień tygodnia (macierz z heat mapą).
Carrier Delay	Fact_Flights (Carrier_Delay_Min)	Średnie opóźnienie z winy przewoźnika. Wykorzystana jako jedna z pięciu serii w wykresie skumulowanym w Raporcie 1.
Weather Delay	Fact_Flights (Weather_Delay_Min)	Średnie opóźnienie spowodowane warunkami atmosferycznymi.
NAS Delay	Fact_Flights (NAS_Delay_Min)	Średnie opóźnienie wynikające z przeciążenia krajowej przestrzeni powietrznej USA.

kontynuacja na następnej stronie

Tabela 3 - kontynuacja z poprzedniej strony

Miara / atrybut	Źródło danych	Definicja
Security Delay	Fact_Flights (Security_Delay_Min)	Średnie opóźnienie spowodowane procedurami bezpieczeństwa.
On-Time Performance (OTP)	Fact_Flights (Is_Arr_Delayed_15)	Procent lotów, które przyleciały z opóźnieniem nieprzekraczającym 15 minut. W Raporcie 3 prezentowany jako ranking przewoźników (format procentowy).
Cancellation Rate	Fact_Flights (Is_Cancelled)	Procent odwołanych lotów względem wszystkich zaplanowanych operacji, liczony per lotnisko/ przewoźnik. Jedna z miar zweryfikowanych na stronie testowej (sekcja ??).
Cancellation Rate by Reason (nowość)	Fact_Flights (Is_Cancelled, Cancellation_Reason)	Wariant Cancellation Rate, w którym mianownik (wszystkie loty) jest zawsze liczony bez filtra na kolumnie Cancellation_Reason (REMOVEFILTERS) - dzięki temu suma udziałów poszczególnych przyczyn na wykresie skumulowanym faktycznie odpowiada całkowitemu wskaźnikowi odwołań danego lotniska.
Flight Count (nowość)	Fact_Flights (COUNTROWS)	Prosty licznik lotów. Użyty jako rozmiar punktów na wykresie rozrzutu DPI vs Late Aircraft Delay (Raport 1) - większy punkt = lotnisko z większym ruchem.
Wildlife Impact Ratio (WIR)	Fact_Strikes, Fact_Flights	Stosunek liczby incydentów ze zwierzętami (FAA) do liczby operacji lotniczych, per lotnisko i rok. Wykorzystany na osi X wykresu rozrzutu w Raporcie 2 oraz na stronie testowej.
Average AOS by Animal Size	Fact_Strikes (Aircraft_Out_Of_Service_Hrs, Bird_Size)	Średni czas wyłączenia samolotu z eksploatacji (wsgodzinach) w podziale na kategorię wielkości zwierzęcia (Small / Medium / Large).
Average AOS by Damage Level	Fact_Strikes (Aircraft_Out_Of_Service_Hrs, Dim_Damage_Level)	Średni czas AOS w podziale na poziom uszkodzenia, posortowany według kolumny pomocniczej Severity_Order (a nie alfabetycznie).

kontynuacja na następnej stronie

Tabela 3 - kontynuacja z poprzedniej strony

Miara / atrybut	Źródło danych	Definicja
Strike Count by Flight Phase	Fact_Strikes, Dim_Flight_Phase	Liczba incydentów ze zwierzętami w podziale na fazę lotu, sortowana malejąco - włącznie z kategorią "UKN" (faza nieznana), która jest realną wartością ze źródła FAA, a nie błędem ładowania (więcej w sekcji 6.4).
Average Delay by Distance Category	Fact_Flights (opóźnienie przylotu, Distance_Category)	Średnie opóźnienie przylotu w podziale na kategorię odległości trasy (zob. kolumny obliczeniowe poniżej).

6.2.1 Kolumny obliczeniowe dodane w warstwie raportowej

Przy budowie raportów okazało się, że kilku elementów nie da się sensownie pokazać odbiorcy biznesowemu bez dodatkowych kolumn obliczeniowych w modelu. Wszystkie zostały dodane po stronie Power BI (nie w hurtowni), ponieważ mają charakter czysto prezentacyjny / porządkujący.

Nazwa przewoźnika. Wymiar Dim_Carrier zawiera jedynie kod przewoźnika (Carrier_Code), bez pełnej nazwy, co dla odbiorcy nieznającego kodów IATA linii lotniczych jest nieczytelne. Dodano dwie kolumny obliczeniowe:

Carrier_Display (np. "DL - Delta Air Lines") jest tym, co faktycznie widać na fragmentatorach i wykresach - sam kod zostałby zrozumiany tylko przez osobę znającą skróty linii lotniczych. Mapowanie obejmuje przewoźników faktycznie obecnych w danych; gdyby pojawił się kod spoza listy, kolumna wyświetla kod (nieznany kod).

Kategoria odległości trasy. Do wykresu "Średnie opóźnienie wg kategorii odległości" w Raporcie 3 potrzebny był podział lotów na krótkie/średnie/długie trasy.

Druga kolumna (Distance_Category_Order) jest techniczna, bez niej Power BI sortowałby kategorie alfabetycznie ("Długa", "Krótka", "Średnia"), co na wykresie wyglądałoby nielogicznie. Ustawiono ją jako kolumnę sortującą ("Sortuj według kolumny") dla Distance_Category.

Przyczyna odwołania lotu. Kolumna Cancellation_Code w Fact_Flights zawiera jednoliterowe kody A/B/C/D zgodne ze standardem BTS. Na potrzeby wykresu odwołań w Raporcie 3 dodano tłumaczenie.

6.3 Hierarchie analityczne

Wszystkie hierarchie zaplanowane w KM2 (sekcja 4.2) zostały odwzorowane w modelu Power BI, jednak część z nich różni się od planu - ze względu na rzeczywiste nazwy kolumn w finalnym modelu gold, inne niż zakładano na etapie planowania. Finalny stan:

- **Hierarchia datowa (Dim_Date):**

Year → Quarter → Month_Name → Day

(w planie był poziom Week - w finalnym modelu nie został wykorzystany, ponieważ przy danych

Fact_Flights obejmujących jeden rok podział tygodniowy nie wnosił nic do żadnego z trzech raportów; **Month_Name** jest dodatkowo sortowany według kolumny **Month**, żeby miesiące pojawiały się w kolejności styczeń -grudzień, a nie alfabetycznie).

- **Hierarchia czasowa (godzinowa) (Dim_Time):**
Day_Period → Time_Block → Hour_24 → Minute
(w planie była kolumna Hour - w modelu gold nazywa się Hour_24 i zawiera wartości 0 - 23).
- **Hierarchia geograficzna (Dim_Airport):**
Country → City_Name → Airport_Name
- **Hierarchia fazy lotu (Dim_Flight_Phase):**
Phase_Group → Phase_Name
- **Hierarchia uszkodzeń (Dim_Damage_Level):**
Severity_Order → Damage_Description
(Severity_Order jest kolumną liczbową ustawioną jako sortowanie dla Damage_Description, dzięki czemu poziomy uszkodzeń pojawiają się w logicznej kolejności: brak → drobne → znaczne → zniszczony, a nie alfabetycznie).

Hierarchia opóźnień zaplanowana w KM2 (*Total Delay* → *Carrier/Weather/NAS/ Security/Late Aircraft Delay*) nie została zaimplementowana jako osobny obiekt hierarchii w Power BI. W DAX nie da się zbudować nawigowalnej hierarchii z pięciu niezależnych miar. W praktyce ten podział jest zrealizowany inaczej: wszystkie pięć miar opóźnień (Carrier, Weather, NAS, Security, Late Aircraft Delay) jest wyświetlanych razem na jednym wykresie skumulowanym w Raporcie 1, co daje ten sam efekt analityczny (rozkład opóźnień na przyczyny), tylko w formie wizualizacji, a nie hierarchii pól.

6.4 Obserwacje dotyczące jakości danych istotne dla raportów

Podczas budowy raportów napotkano kilka cech danych, które na pierwszy rzut oka wyglądały jak błąd, a w rzeczywistości są właściwościami źródeł albo świadomą decyzją z etapu ETL. Warto je odnotować, bo bezpośrednio wpłynęły na decyzje projektowe w raportach:

- **Fact_Flights (BTS) zawiera dane tylko z roku 2025.** Pierwotnie w Raporcie 1 planowany był wykres trendu DPI w osi czasu opartej na **Full_Date**, przy danych z jednego roku taki wykres związał się do jednego punktu. Wykres trendu został przez to zmieniony na osi **Month_Name** (12 punktów w obrębie 2025), co lepiej odzwierciedla realne dane i jest bardziej użyteczne dla odbiorcy.
- **Fact_Strikes (FAA) zawiera dane wieloletnie.** Według raportu jakości danych zakres dat incydentów FAA wynosi 1990-01-02 - 2026-04-13, czyli obejmuje wiele lat, w przeciwieństwie do **Fact_Flights**. W konsekwencji wizualizacje Raportu 2 oparte na **Month_Name** (np. mapa cieplna "liczba incydentów wg lotniska i miesiąca") agregują incydenty z wielu lat w ramach tego samego miesiąca kalendarzowego. Jest to odnotowane jako obserwacja dotycząca interpretacji wykresu. Styczeń na osi nie oznacza stycznia 2025, a sumę wszystkich incydentów ze stycznia z całego dostępnego zakresu lat.
- **Wiersz "Unknown" w Dim_Date.** Wymiar zawiera pomocniczy rekord reprezentujący nieznaną/brakującą datę (m.in. **Month_Name** = "Unknown", rok ok. 1900). Bez filtra ten rekord ciągnął oś X wykresu trendu do roku 1900, co wizualnie spłaszczało cały wykres. Dlatego na wizualizacjach opartych na **Dim_Date** dodano filtr **Month_Name** ≠ "Unknown".


6.5 Realizacja raportów

Wszystkie trzy raporty zostały zrealizowane na osobnych stronach w jednym pliku. Dodatkowo dodano czwartą stronę, opisaną w sekcji ??, służącą wyłącznie do weryfikacji miar.

6.5.1 Raport 1: Propagacja opóźnień

Strona zawiera trzy fragmentatory (Miesiąc - Month_Name, Lotnisko - Airport_Name, Przewoźnik - Carrier_Display) oraz pięć wizualizacji:

- **"Mapa lotnisk USA - Delay Propagation Index"** - mapa Bing (wizualizacja typu Mapa), z Latitude/Longitude jako lokalizacją, Airport_Name w szczegółach i kolorem punktu wg DPI.
- **"TOP 10 lotnisk pod względem DPI"** - wykres słupkowy skupiony, z filtrem Top N = 10 wg DPI.
- **"DPI vs Late Aircraft Delay"** - wykres punktowy: DPI na osi X, Late Aircraft Delay na osi Y, Airport_Name w polu Szczegóły (definiuje granulację - jeden punkt = jedno lotnisko), wielkość punktu: Flight Count. Kolor jednolity (niebieski) - rozróżnianie kolorem wg kategorii zostało wyłączone, ponieważ przy kilkudziesięciu lotniskach paleta kolorów robiła się nieczytelna.
- **"Struktura opóźnień przylotu wg miesiąca"** - wykres skumulowany (kolumnowy), osie X = Month_Name, wartości = pięć miar opóźnień (Carrier, Weather, NAS, Security, Late Aircraft Delay), kolory: poszczególne przyczyny.
- **"Trend DPI w 2025 roku"** - wykres liniowy, oś X = Month_Name, wartość: DPI (zmiana względem planu opisana w sekcji 6.4).




Rysunek 3: Raport 1 - Propagacja opóźnień (widok finalny)

6.5.2 Raport 2: Incydynty FAA

Strona koncentruje się na incydentach ze zwierzętami i ich wpływie na operacje:

- **"Wildlife Impact Ratio vs Average Arrival Delay"** - wykres punktowy: WIR na osi X, Average Arrival Delay na osi Y, Airport_Name w Szczegółach, wielkość punktu = liczba incydentów (Strike Count).
- **"Średni czas wyłączenia samolotu (AOS) wg wielkości zwierzęcia"** - wykres słupkowy skupiony, kategorie: Bird_Size (Small/Medium/Large).
- **"Średni czas AOS wg poziomu uszkodzeń"** - wykres słupkowy skupiony, kategorie: Damage_Description, sortowane wg Severity_Order.
- **"Liczba incydentów wg fazy lotu"** - wykres słupkowy skupiony, kategorie: Phase_Name, sortowane malejąco wg liczby incydentów (zawiera kategorię UKN, zob. sekcja 6.4).
- **"Mapa cieplna: liczba incydentów wg lotniska i miesiąca"** - macierz (Matryca) z wierszami Airport_Name (filtr Top 15), kolumnami Month_Name i wartością Strike Count, z formatowaniem warunkowym typu skala kolorów (heat map).

Raport nie zawiera dedykowanego filtra roku. Biorąc pod uwagę wieloletni zakres danych Fact_Strikes (zob. sekcja 6.4), dodanie takiego filtra (np. jako fragmentator Year) byłoby wartościowym rozszerzeniem raportu w kolejnej iteracji - w obecnej wersji wizualizacje prezentują dane zagregowane po wszystkich dostępnych latach.




Rysunek 4: Raport 2 - Incydynty FAA (widok finalny)

6.5.3 Raport 3: Wzorce opóźnień

Strona zawiera dwa fragmentatory (Przewoźnik - Carrier_Display, Miesiąc - Month_Name) oraz cztery wizualizacje:

- "Mapa cieplna opóźnień: godzina odlotu x dzień tygodnia" - macierz, wiersze = Hour_24 (0-23), kolumny = Day_Name (sortowane wg Day_Of_Week, a nie alfabetycznie), wartość: Average Arrival Delay, z formatowaniem warunkowym (heat map).
- "Średnie opóźnienie przylotu wg kategorii odległości trasy" - wykres słupkowy skupiony, kategorie = Distance_Category (sortowane wg Distance_Category_Order).
- "Wskaźnik odwołań lotów wg lotniska i przyczyny (TOP 10)" - wykres skumulowany, oś X: Airport_Name (filtr Top 10), wartość: Cancellation Rate by Reason, kolory: Cancellation_Reason.
- "Ranking przewoźników według On-Time Performance (OTP)" - wykres słupkowy skupiony (poziomy), kategorie: Carrier_Display, wartość: OTP w formacie procentowym, sortowanie malejące.



Rysunek 5: Raport 3 - Wzorce opóźnień (widok finalny)

6.5.4 Filtry raportu

W trakcie pracy ustawiono filtr Country = "United States" (zawężający dane do lotnisk amerykańskich, zgodnie z zakresem danych BTS). Filtr ten został zastosowany na poziomie strony każdego z trzech raportów. Strona testowa pozostała bez żadnych dodatkowych filtrów.

7 Podsumowanie rezultatów

Zrealizowano kompletną hurtownię danych w architekturze medalionowej (Bronze → Silver → Gold) wraz z warstwą raportową. Z perspektywy biznesowej rozwiązanie osiągnęło zakładane cele:

- **Kompletność danych:** załadowano blisko 7,0 mln rekordów lotów (12 pełnych miesięcy 2025 r.) oraz 342 830 incydentów ze zwierzętami (zakres 1990–2026), zintegrowanych z 7 wymiarami w modelu gwiazdy.
- **Jakość danych:** wskaźnik błędów ETL dla danych BTS wynosi 0,008 % (poziom bardzo dobry), a integralność referencyjna jest zachowana dzięki polityce klucza zastępczego SK = -1 (brak wartości NULL w kluczach obcych) — szczegóły w Raporcie Jakości Danych.
- **Wartość analityczna:** model umożliwia realizację trzech scenariuszy analitycznych (propagacja opóźnień, incydenty FAA, wzorce opóźnień) zaprezentowanych w postaci trzech raportów Power BI.

Ograniczenia. Dane lotów (BTS) obejmują pojedynczy rok (2025), co ogranicza analizy trendów wieloletnich w tym obszarze. Wysoki udział kluczy SK = -1 w fakcie incydentów (np. 62,4 % dla przewoźnika) wynika ze specyfiki źródła FAA (operatorzy prywatni, rządowi i wojskowi spoza zbioru przewoźników komercyjnych) i jest zachowaniem oczekiwanym, nie błędem.

8 Podział pracy w zespole

Projekt realizował trzyosobowy zespół. Podział odpowiedzialności obejmował projekt, implementację, testy oraz dokumentację:

Osoba	Rola	Zakres prac
Maciej Winkler	Inżynier Danych (Data Engineer)	Implementacja fizycznego modelu hurtowni (tabele, relacje); moduł pozyskiwania i przetwarzania danych ETL/ELT (Mapping Data Flows Bronze→Silver, procedury składowane Silver→Gold); analiza jakości danych. Dokumentacja: opis zbiorów danych, opis procesu ETL, model fizyczny hurtowni.
Kamila Więckowska	Deweloper BI (BI Developer)	Implementacja warstwy OLAP/BI w Power BI (źródła, model, hierarchie, miary, KPI); przygotowanie finalnych raportów biznesowych. Dokumentacja: opis kluczowych miar i hierarchii, opis warstwy raportowej, opis realizacji raportów; wygenerowanie raportów w formacie PDF.

Osoba	Rola	Zakres prac
Nazarii Bihniak	Dev Ops i Lider Projektu (QA & Tech Lead)	Opracowanie i przeprowadzenie testów funkcjonalnych (konfiguracja ADF i bazy danych, wszystkie warstwy, E2E, scenariusze ładowania, spójność danych); weryfikacja jakościowa i naprawa wykrytych defektów ETL. Dokumentacja: cel projektu i korzyści, diagram i opis architektury, podsumowanie rezultatów, podział pracy. Złożenie kodu, plików konfiguracyjnych i dokumentacji w jedną paczkę.

9 Testy funkcjonalne

Pełny zestaw testów funkcjonalnych (wszystkie warstwy, E2E, scenariusze ładowania, spójność danych) znajduje się w osobnym dokumencie *testy_funkcjonalne.md* / *testy.docx*. Poniżej skrót.

Warstwa / test	Cel	Wynik
ETL Bronze→Silver (1.1–1.2)	Kompletność i standaryzacja danych, kolumny audytowe	✓ (po naprawie defektów)
Hurtownia (2.1)	Kompletność faktów	✓ 6 991 619 lotów / 342 830 incydentów
Hurtownia (2.2)	Integralność referencyjna (sentinel SK=-1)	✓ brak NULL w kluczach obcych
Hurtownia (2.3)	Poprawność SCD Type 2	✓ 0 duplikatów wersji bieżącej
Hurtownia (2.4)	Dekodowanie kodów FAA	✓ wartości słownikowe
BI / model (3.1–3.2)	Połączenie, poprawność miar DPI/WIR/OTP	w toku (zrzuty Power BI)
Raporty (4.1)	Zgodność liczb raportu z hurtownią	✓ wartości kontrolne SQL
E2E (5.1–5.2)	Spójność Silver→staging→Gold; pełny przebieg	✓ 582 304 (Dec) spójne; pipeline Succeeded
Ładowanie (6.1)	Inicjalizacja 12 miesięcy	✓ 12/12 iteracji Succeeded
Ładowanie (6.2)	Idempotencja kolejnej iteracji	✓ liczba wierszy niezmiennona

Defekty wykryte i naprawione. Testy spójności ujawniły dwa błędy ETL: (D1) parametr `limit: 1000` ograniczający warstwę Silver do 1000 wierszy/miesiąc oraz (D2) błędną maskę parsowania daty `FL_DATE`. Oba naprawiono, a warstwy Silver i Gold przeładowano (szczegóły w *testy_funkcjonalne.md*, sekcja 8).